Projet Kayak : Plan Your Trip

Optimiser le choix de destination et d'hébergement en France grâce à l'ingénierie des données.

Made with GAMMA

Le Besoin Métier

Le Problème

70% des utilisateurs de Kayak réclament des informations objectives et fiables sur leur destination avant de valider une réservation.

La Mission

Construire un pipeline de données de bout en bout pour **identifier les meilleures opportunités parmi le Top 35 des villes françaises**, en croisant météo réelle et qualité hôtelière.

Made with GAMMA

L'Architecture du Pipeline

De la source web à la carte interactive — quatre étapes clés structurent le flux de données.

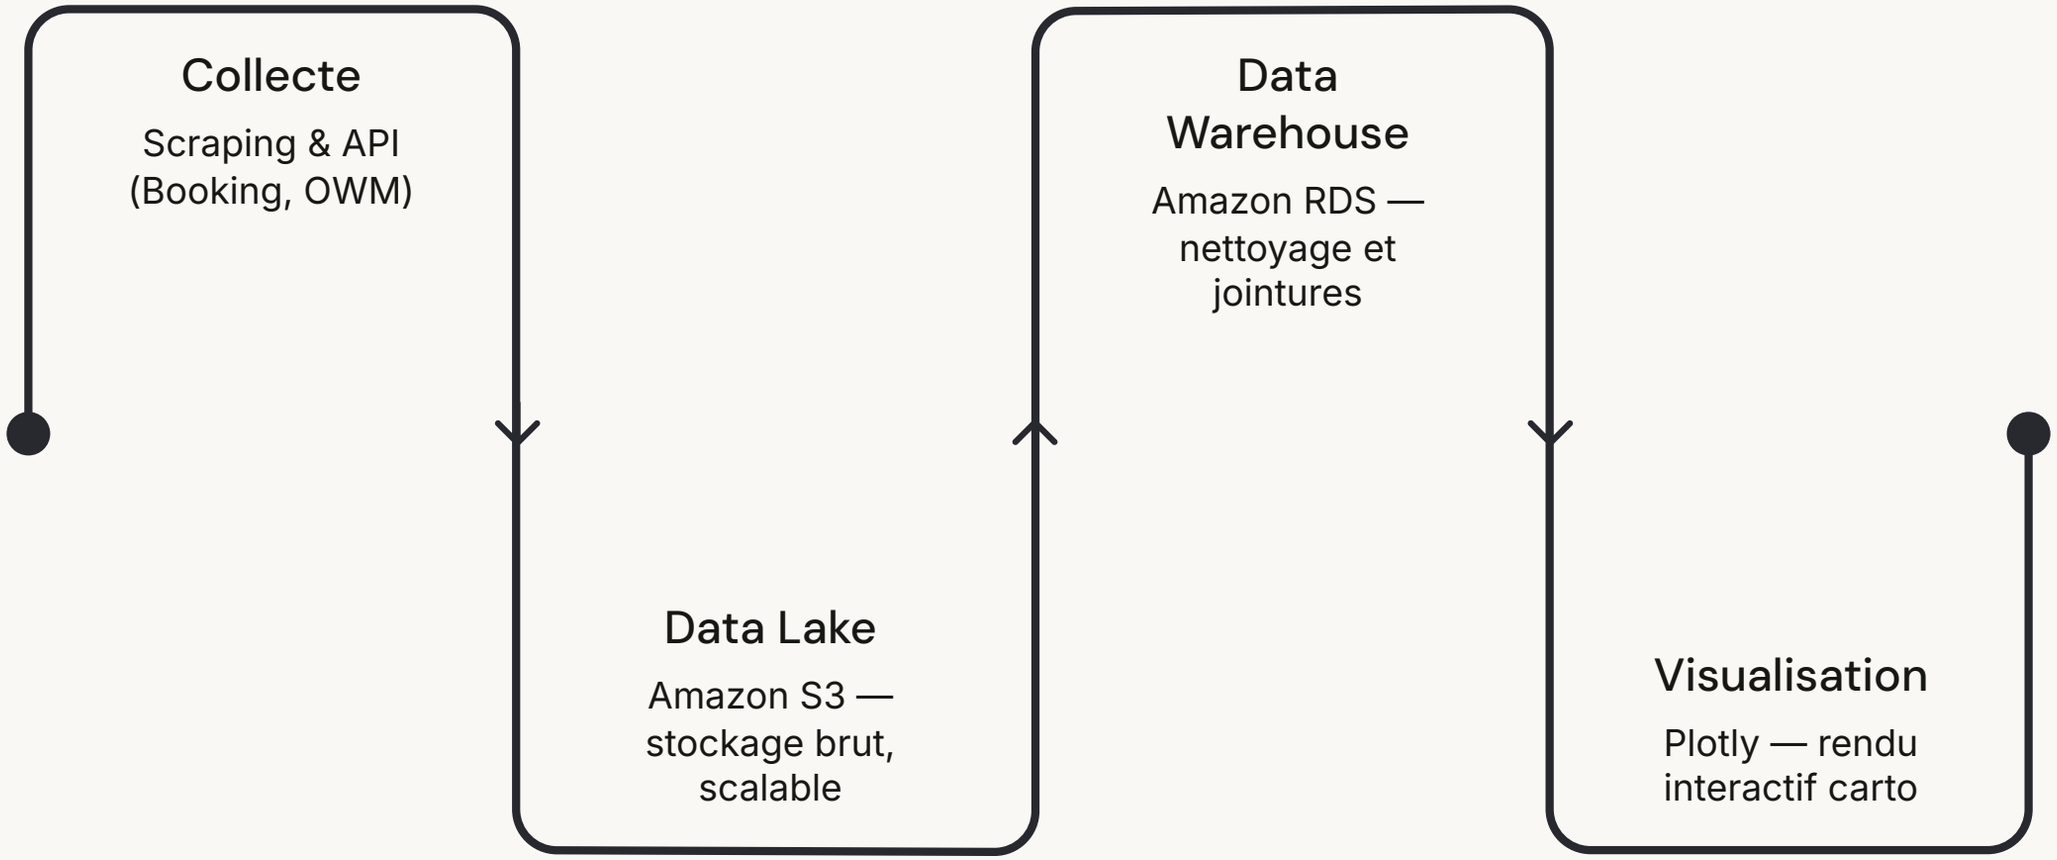

Un pipeline complet allant de la collecte à la visualisation, avec des boucles de rétroaction entre les couches S3, RDS et l'interface finale.

Made with GAMMA

Le Score Météo & l'Extraction Booking.com

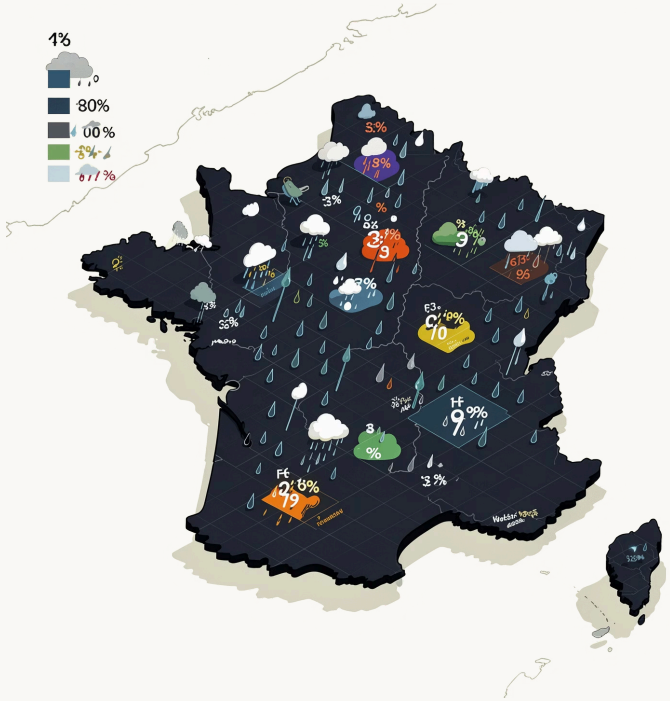

L'équation météo

Température moyenne (°C) – Probabilité de pluie (%) = Score de destination

Modélisation via **API One Call 3.0** (OpenWeatherMap) + géocodage Nominatim, générant un `city_id` unique par ville.

Scraping Booking.com

880 établissements extraits via Scrapy / Selenium sur 35 villes : nom, étoiles, note, prix/nuit, description, localisation.

Made with GAMMA

Contourner les Protections Anti-Bot

AWS WAF

Web Application Firewall avec Code HTTP 202, JS Challenges et TLS Fingerprinting.

Cookies de session réels

Extraction locale (`cookie.txt`) pour simuler une session humaine authentique.

Rotation User-Agent

Usurpation d'empreinte Chrome standard pour éviter le fingerprinting.

DOWNLOAD_DELAY

Rate-limiting configuré pour esquiver les seuils d'alerte du pare-feu.

Note technique : Snapshot CSV local pour pallier la péremption rapide des cookies.

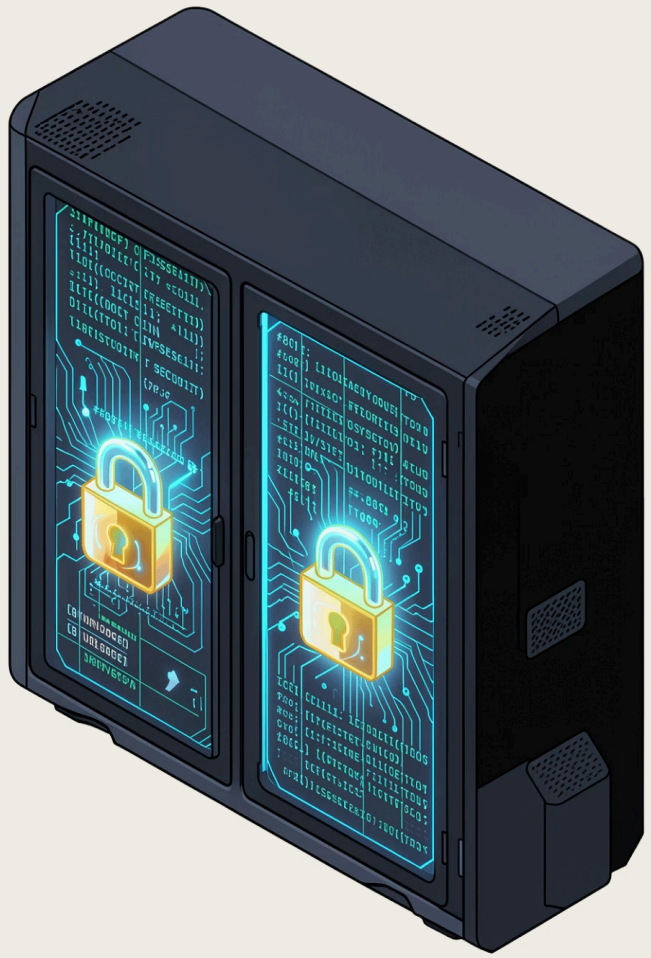

Made with GAMMA

Géocodage Asynchrone & Stratégie Cloud

Géocodage post-scraping

Les coordonnées GPS sont injectées dynamiquement via JS. **Nominatim (OpenStreetMap)** résout les adresses → lat/lon.

699 hôtels localisés avec précision sur 880 — adresses ambiguës éliminées.

S3 vs RDS

Amazon S3

Données brutes, schema-on-read, traçabilité, ~0.023$/Go/mois

Amazon RDS

Données nettoyées, schema-on-write, performance SQL, intégrité référentielle

Made with GAMMA

Le Moteur ETL & la Modélisation SQL

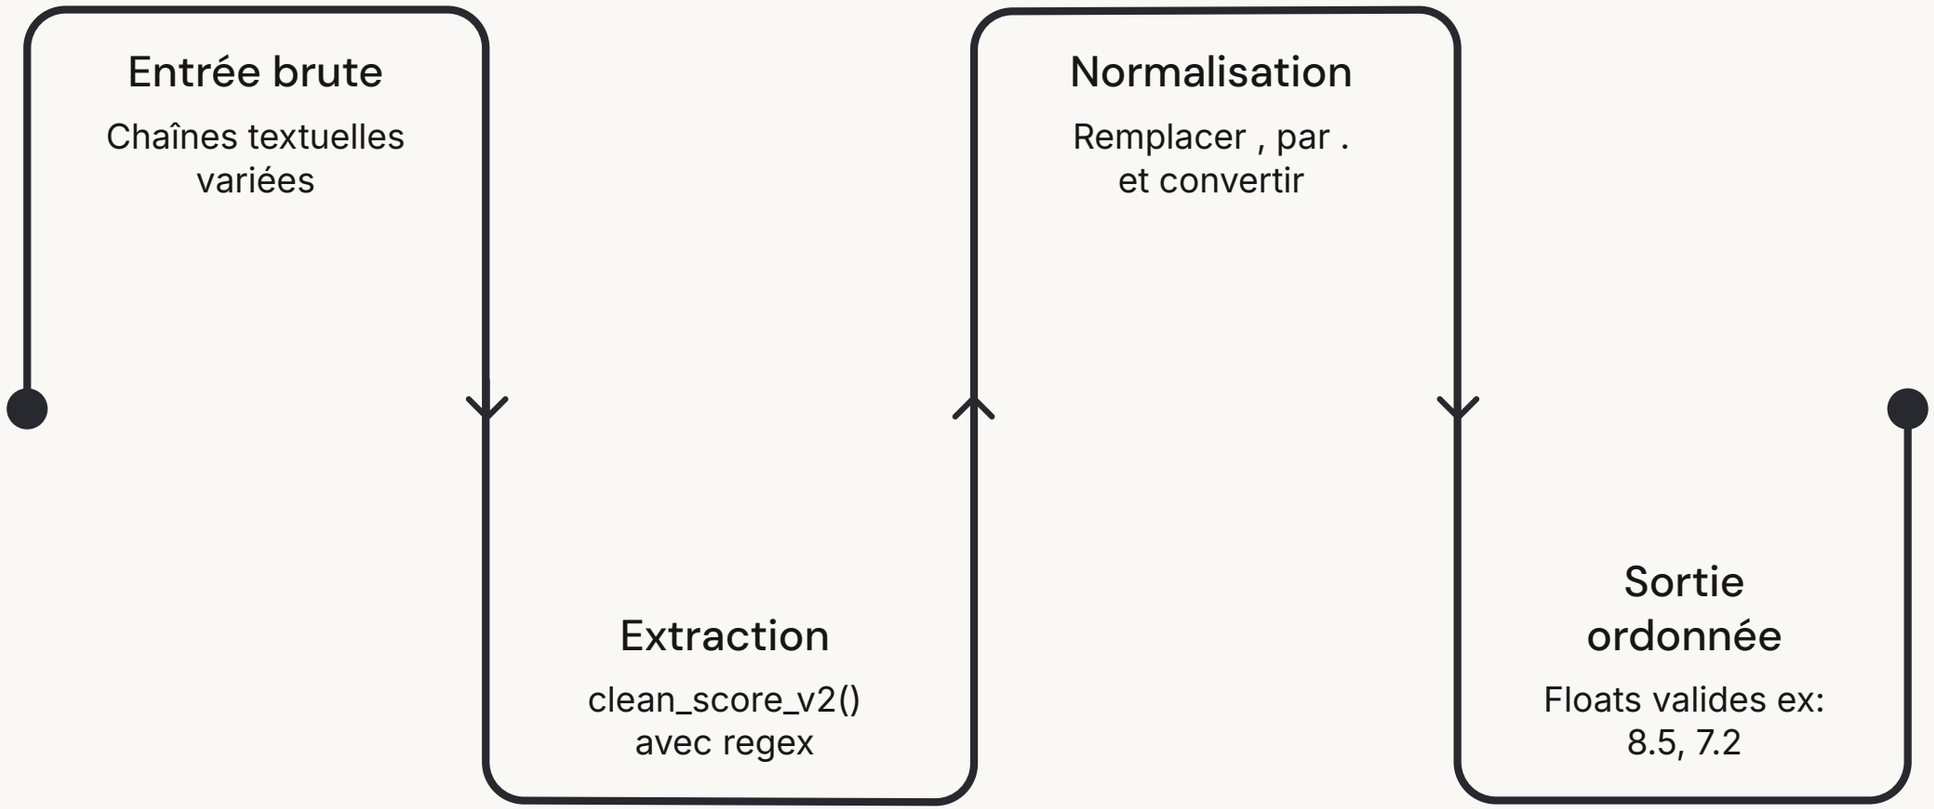

La fonction `clean_score_v2()` extrait les scores numériques via regex. Validation géolocalisation : `dropna(subset=['latitude', 'longitude'])` avant insertion RDS.

Modèle relationnel

Table **weather** (35 villes, PK `city_id`) reliée à **hotels** (699 établissements, FK `city_id`) — jointure pour croiser météo et qualité hôtelière.

Made with GAMMA

Panorama Météo : Top 5 des Destinations

13.4

Bormes-les-Mimosas

14.6°C · 1% pluie

9.7

Cassis

15.0°C · 11% pluie

3

Paris

11.7°C

4

Mont-Saint-Michel

8.6°C

5

La Rochelle

11.7°C

Rendu **carto-positron** (Jupyter/Plotly) — style optimisé pour la visualisation géographique interactive.

Made with GAMMA

Panorama Hôtelier & Bilan de l'Architecture

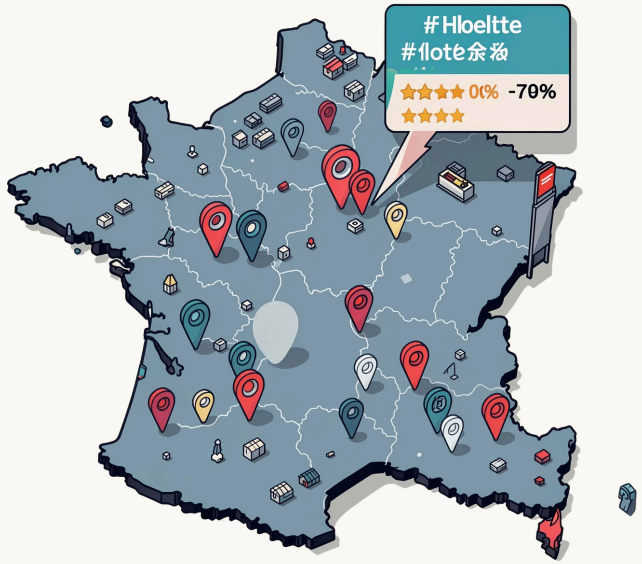

Top 20 hôtels

Affichage exclusif des hôtels les mieux notés dans les **5 villes lauréates** — aide à la décision croisant budget et confort.

Points forts

- Pipeline 100% fonctionnel de la source web à l'UI
- Séparation claire S3 (froid) / RDS (chaud)

Axes de consolidation

- Fragmentation ETL : centraliser `etl_booking.ipynb` et `meteo_cartes.ipynb`
- Remplacer les CSV manuels par un versioning DVC en production

Made with GAMMA

Perspectives d'Industrialisation

Automatisation Real-Time

Remplacement de l'exécution manuelle par **AWS Lambda** ou **Apache Airflow** pour des mises à jour quotidiennes de la météo et des prix.

Intelligence Artificielle (NLP)

Analyse de sentiment sur les descriptions textuelles des hôtels scrapés pour affiner la pertinence du score.

Produit Final (UI)

Déploiement d'un **dashboard interactif public via Streamlit** offrant des filtres de budget et de température à l'utilisateur final.

Made with GAMMA